Victor-Emmanuel Brunel

Sigalla & Cloarec

Notes optimisation avancée

Théorème 0.1. *Soit f une fonction réelle α-fortement convexe et L-lipschitzienne sur E. Soit $x^\star := \arg\min_{x\in E} f(x)$. On a le résultat suivant:*

$$f(\hat{x}) - f(x^\star) \leq \frac{2L^2}{\alpha T} \tag{1}$$

Démonstration. Pour $t = 1$ à T, introduisons le pas:

$$\mu_t := \frac{2}{\alpha t} \tag{2}$$

En utilisant l'identité classique $2\langle x\,,\,y\rangle = \|x+y\|^2 - \|x\|^2 - \|y\|^2$, on a pour $t = 0$ à $T-1$:

$$\begin{aligned}
f(\hat{x}) - f(x^\star) &\leq f(x_t) - \left(f(x_t) + u_t^T\left(x^\star - x_t\right) + \frac{\alpha}{2}\left\|x^\star - x_t\right\|^2 \right) \\
&= -u_t^T\left(x^\star - x_t\right) - \frac{\alpha}{2}\left\|x^\star - x_t\right\|^2 \\
&= -\frac{\mu_{t+1}}{\mu_{t+1}}\cdot u_t^T\left(x^\star - x_t\right) - \frac{\alpha}{2}\left\|x^\star - x_t\right\|^2 \\
&= \frac{1}{2\mu_{t+1}}\left(\left\|\mu_{t+1}\cdot u_t\right\|^2 + \left\|x^\star - x_t\right\|^2 - \left\|\mu_{t+1}\cdot u_t + x^\star - x_t\right\|^2 \right) - \frac{\alpha}{2}\left\|x^\star - x_t\right\|^2 \\
&= \frac{1}{2\mu_{t+1}}\left(\left\|\mu_{t+1}\cdot u_t\right\|^2 + \left\|x^\star - x_t\right\|^2 - \left\|x^\star - y_t\right\|^2 \right) - \frac{\alpha}{2}\left\|x^\star - x_t\right\|^2 \\
&\leq \frac{1}{2\mu_{t+1}}\left(\mu_{t+1}^2\cdot L^2 + \left\|x^\star - x_t\right\|^2 - \left\|x^\star - x_{t+1}\right\|^2 \right) - \frac{\alpha}{2}\left\|x^\star - x_t\right\|^2 \\
&= \frac{\mu_{t+1}L^2}{2} + \underbrace{\left(\frac{1}{2\mu_{t+1}} - \frac{\alpha}{2} \right)}_{\frac{\alpha(t-1)}{4}}\left\|x^\star - x_t\right\|^2 - \underbrace{\frac{1}{2\mu_{t+1}}}_{\frac{\alpha(t+1)}{4}}\left\|x^\star - x_{t+1}\right\|^2
\end{aligned}$$

En utilisant la définition de $\hat{x}$, la convexité de f et l'inégalité d'au-dessous pour tout t, on a successivement:

$$\begin{aligned}
f(\hat{x}) - f(x^\star) &= f\left(\sum_{t=0}^{T} \frac{2t}{T(T+1)} x_t \right) - f(x^\star) \\
&\leq \sum_{t=0}^{T} \frac{2t}{T(T+1)} \left(f(x_t) - f(x^\star) \right) \\
&\leq \sum_{t=0}^{T} \frac{2t}{T(T+1)} \left(\frac{\mu_{t+1}L^2}{2} + \frac{\alpha(t-1)}{4}\cdot\left\|x^\star - x_t\right\|^2 - \frac{\alpha(t+1)}{4}\cdot\left\|x^\star - x_{t+1}\right\|^2 \right) \\
&\leq \underbrace{\sum_{t=0}^{T} \frac{t}{T(T+1)}\mu_{t+1}L^2}_{:=A} + \underbrace{\sum_{t=0}^{T} \frac{\alpha t}{2T(T+1)} \left((t-1)\cdot\left\|x^\star - x_t\right\|^2 - (t+1)\cdot\left\|x^\star - x_{t+1}\right\|^2 \right)}_{:=B}
\end{aligned}$$

En posant $\delta_t := t(t-1)\cdot\left\|x^\star - x_t\right\|^2$, on peut réécrire la somme de gauche:

$$B = \frac{\alpha}{2T(T+1)}\sum_{t=0}^{T}(\delta_t - \delta_{t+1}) = \frac{\alpha}{2T(T+1)}(\delta_1 - \delta_{T+1}) \le 0$$

Montrons maintenant que $A \le \frac{2L^2}{\alpha T}$. En utilisant la définition du pas μ_t, on a:

$$A = \frac{L^2}{T(T+1)}\sum_{t=0}^{T}\frac{2t}{\alpha(t+1)} = \frac{2L^2}{\alpha T}\cdot\frac{1}{(T+1)}\sum_{t=0}^{T}\underbrace{\frac{t}{t+1}}_{\le 1} \le \frac{2L^2}{\alpha T}$$

d'où le résultat. □

Un exemple très important est celui des fonctions α-fortement convexe et β régulière. Remarquons que nécessairement $\alpha \le \beta$.

1 Cas de fonctions α-fortement convexe et β régulière

Soit $f : \mathbb{R}^d \mapsto \mathbb{R}$ une fonction α-fortement convexe et β régulière. On a donc pour tout x, x_0 appartenant à $\mathbb{R}^d$:

β-régularité $f(x) \le f(x_0) + \nabla f(x_0)^T(x - x_0) + \frac{\beta}{2}\|x - x_0\|^2$

α-fortement convexe $f(x_0) + \nabla f(x_0)^T(x - x_0) + \frac{\alpha}{2}\|x - x_0\|^2 \le f(x)$

Plusieurs cas :

— Si $\alpha = \beta$, cela signifie que f est quadratique ;

— si $\alpha \neq \beta$, alors nécessairement $\alpha \le \beta$.

— Si $\alpha \approx \beta$, alors on peut confondre la courbe de f et la courbe de β et on peut alors trouver le minimum très facilement.

Théorème 1.1. *En reprenant les hypothèses sur f introduites au-dessus, on a le résultat suivant*

$$\left\|\hat{x} - x^\star\right\|^2 \le \mathrm{e}^{-\frac{T}{K}\cdot\|x_0 - x^\star\|} \tag{3}$$

où $K := \frac{\beta}{\alpha}$.

Démonstration. Montrons tout d'abord l'égalité suivante:

$$f(\hat{x}) - f(x^\star) = \int_0^1 \nabla f\left(x^\star + t(\hat{x} - x^\star)\right)^T \cdot \left(\hat{x} - x^\star\right)\mathrm{d}t \tag{4}$$

En introduisant la fonction auxiliaire $\phi(t) := f\left(x^\star + t(\hat{x} - x^\star)\right)$ définie sur $[0;1]$, on a :

$$\phi(1) - \phi(0) = \int_0^1 \phi'(t)\,\mathrm{d}t = \int_0^1 \nabla f\left(x^\star + t(\hat{x} - x^\star)\right)^T \cdot \left(\hat{x} - x^\star\right)\mathrm{d}t$$

ce qui montre (1) .

En utilisant la forme intégrale pour $f(\hat{x}) - f(x^\star)$, on a donc succcessivement:

$$\begin{aligned}
f(\hat{x}) - f(x^\star) &= \int_0^1 \nabla f\left(x^\star + t(\hat{x} - x^\star)\right) - \nabla f(x^\star)^T \cdot \left(\hat{x} - x^\star\right) \mathrm{d}t \\
&\leq \int_0^1 \left\|\nabla f\left(x^\star + t(\hat{x} - x^\star)\right) - \nabla f(x^\star)\right\| \cdot \left\|\hat{x} - x^\star\right\| \mathrm{d}t \\
&\leq \int_0^1 \beta \left\|t(\hat{x} - x^\star)\right\| \cdot \left\|\hat{x} - x^\star\right\| \mathrm{d}t \\
&= \beta \left\|\hat{x} - x^\star\right\|^2 \cdot \int_0^1 t \,\mathrm{d}t \\
&= \frac{\beta \left\|\hat{x} - x^\star\right\|^2}{2} \\
&\leq \frac{\beta}{2} \mathrm{e}^{-T/K} \cdot \left\|x_0 - x^\star\right\|
\end{aligned}$$

Remarque à propos de la complexité de cet alogrithme:

— il faut que l'on ne parte pas trop loin de $x^\star$ à cause de la dépendance au terme $\left\|x_0 - x^\star\right\|$.

— La complexité est en $\log(\frac{1}{\varepsilon})$ ce qui est très rapide. Si $\varepsilon \sim 10^{-9}$, $\log(\frac{1}{\varepsilon}) \sim 9$ on l'on a besoin de seulement d'une dizaine d'étages pour avoir une précision à ε-près.

□

2 Exemple de fonction à la fois α-fortement convexe et β régulière

Il suffit de prendre n'importe quelle fonction quadratique (non nulle).
Si $A \in S_d^{++}$, $b \in \mathbb{R}^d$ et $f : \mathbb{R}^d \to \mathbb{R}$, $x \mapsto \frac{1}{2} x^T A x - b^T x$. Alors on a f qui est :

— $\lambda_{\min}(A)$-fortement convexe,

— $\lambda_{\max}(A)$-régulière.

En effet, on a $f \in \mathcal{L}^2$ et $\forall x \in \mathbb{R}^d$, $\nabla^2 f(x) = A$, d'où l'on a bien

$$\forall x \in \mathbb{R}^d, \quad \lambda_{\min} I_d \leq \nabla^2 f(x) \leq \lambda_{\max} I_d$$

En 10 étages, on peut trouver une solution à l'équation $Ax = b$ à ε près, tandis que résoudre cette équation directement donne une complexité très importante.

En effet, f est minimale en $\nabla f(x) = Ax - b = 0 \Leftrightarrow x = A^{-1} b$. En appliquant l'algorithme de descente de gradient, on trouve $\hat{x} \in \mathbb{R}^d$ tel que

$$\left\|\hat{x} - x^\star\right\|^2 \leq \mathrm{e}^{-T/K} \cdot \left\|x_0 - x^\star\right\|^2$$

Si $T >> K \log\left(\frac{1}{\varepsilon}\right) = \frac{\lambda_{\max}}{\lambda_{\min}}$ (condition-number)